

Práctica 5A. Clasificación de texto

Guillermo Ruiz

Entrena un modelo para predecir el emoticón que corresponde al texto. Los textos están en un archivo `.csv` con el texto y la clase. Algunos ejemplos son:

- ("Mi mamá si jala a fumar porro conmigo, pero no tenemos. _EMO", 😞)
- (¡Esperen! No me eliminen ☹️ Puedo explicarlo todo. _EMO_URL, ♥)
- (Hacia tiempo que no hablaba tan bonito con Alejandra _EMO, ☹️)

1. Debe preprocesar los datos, convertirlos a vectores, entrenar un modelo y evaluar su desempeño. Hay un archivo para entrenamiento y otro para prueba. Los archivos son:

- `emojis_train.csv`
- `emojis_test.csv`

Las clases son ['♥', '😊', '😞', '☹️'] que indican la emoción del tweet. Una vez entrenado cada modelo, predecir los datos para el conjunto prueba que se proporciona.

2. Entrega un notebook que contenga el código de la creación de los modelos, así como la evaluación de sus mejores modelos. La evaluación debe incluir
 - Mostrar la matriz de confusión.
 - Calcular la precisión, recall, F-score para macro y micro
 - Comparar los resultados de cada configuración.

Se sugiere usar las métricas de `sklearn`

```
from sklearn.metrics import classification_report
print(classification_report(y_gold, y_predict))
```

Consultar [esta página](#)

3. Para obtener la matriz de confusión podemos usar la función de sklearn. Las columnas y filas están asociadas a las etiquetas que se indican y es una matriz de NxN, en el ejemplo son 4 clases.

```
from sklearn.metrics import ConfusionMatrixDisplay
_ = ConfusionMatrixDisplay.from_predictions(y_test, svc_predict)
```

que da como salida:




Figure 1: image.png

4. Probar diferentes combinaciones de pre procesamiento, vectorización y modelos de aprendizaje para construir el mejor modelo de predicción.