

PCA para preprocesar datos

Guillermo Ruiz

El algoritmo PCA Se puede usar como un paso en el preprocesado de los datos. Si se va a aplicar un algoritmo de clustering, se aconseja primero disminuir la dimensión de los datos. Algoritmos como k-means tienen problemas de desempeño cuando se usan muchas dimensiones. Además, aplicar PCA ayuda a separar los datos de manera automática.

En este ejercicio se usará el conjunto de datos MNIST para medir la calidad de los clusters con y sin PCA.

Leer el conjunto MNIST.

```
X, y = fetch_openml("mnist_784", return_X_y=True, as_frame=False)
```

1. Usar sólo las imágenes con ceros o unos. Reescalar los datos usando [StandardScaler](#). Aplicar PCA para reducir la dimensión a dos y graficar los puntos, el color de los puntos debe indicar la clase a la que pertenece.
 - Aplicar k-means (con `random_state=1`) para separar los dos clusters antes y después de aplicar PCA.
 - Comparar la calidad de los clusters con la métrica `rand_score` de sklearn.
2. Repetir lo mismo pero reducir la dimensión a 50.
 - Dentro de un ciclo `for` aumentar el número de clases de 2 a 10.
 - Aplicar `StandardScaler`.
 - Aplicar kmeans (con `random_state=1`) con y sin PCA.
 - Comparar la calidad de los clusters con la métrica `rand_score`.
3. Contesta la evaluación de esta práctica en el Aula Virtual.