

Detección de plagio

Guillermo Ruiz

En esta actividad, detectar, a nivel básico, por medio de una medida de similitud, el plagio que hay dentro de un conjunto de documentos.

Los datos son documentos de noticias adaptados a la tarea de detección de plagio. En el conjunto de datos del directorio “suspicious-documents”, hay documentos que tienen fragmentos plagiados de los documentos fuente “source-documents”, sin embargo, también hay otros documentos que simulaban plagio pero no se plagió ningún párrafo de los documentos fuente.

La tarea es encontrar el nivel de plagio entre los archivos del directorio “source-documents” y los archivos del directorio “suspicious-documents”.

1. Crea un notebook para obtener la similitud entre dos documentos. Toma los documentos `source-document0001.txt` al `source-document0010.txt` de source-documents y por cada uno, encuentra los 10 archivos de suspicious-documents más parecidos. Indica los nombres y la similitud obtenida.
2. Aplica los preprocesamientos: usa solo letras minúsculas, quita los siguientes caracteres “;,:.\-” ‘/()[]?;!{}~<>|«»—’ ”, remueve stopwords y aplica un proceso de stemming para reducir el vocabulario.

Nota: al usar la lista de stopwords para eliminarlas, si se aplicó stemming, aplicar stemming también a las stopwords debido a que alguna palabra podrían cambiar.

Usa el stemmer de NLTK Porter (inglés). <http://www.nltk.org/howto/stem.html>

Básicamente es usar:

```
from nltk.stem.porter import *
stemmer = PorterStemmer()
word = stemmer.stem('pages')
```

word contendrá la palabra normalizada por medio de stemming (‘page’). Aplicar ese proceso a todos los textos.

3. Para procesar la medida de similitud usar las medidas Jaccard y Dice

4. Contesta la evaluación de esta práctica en el Aula Virtual.

Los datos son archivos de texto plano UTF-8 en inglés:

- source-documents.zip.
- suspicious-documents.zip.